

Rapport d'Audit de la Qualité des Données (Jeu de données médicales)

1. Résumé Exécutif

Le présent rapport évalue la qualité d'un échantillon de données composé de 12 enregistrements au format JSON. Ce dataset est structuré sous la forme de paires instruction (représentant la question du patient) et output (représentant la réponse et l'orientation médicale du médecin). L'objectif de cet audit est de vérifier la structure, la complétude, la cohérence du formatage et la propreté textuelle de ces données en vue d'un éventuel traitement par une intelligence artificielle.

2. Aperçu du Jeu de Données

L'échantillon analysé comprend les caractéristiques globales suivantes :

Métrique	Valeur constatée
Nombre total de lignes	12 enregistrements
Colonnes présentes	instruction, output
Taux de valeurs manquantes	0% (aucune valeur null)
Format du fichier	JSON brut (Objets par ligne)

3. Analyse Structurelle et Formatage

Cohérence de la colonne instruction

- **Préfixe systématique** : Toutes les entrées de la colonne instruction adoptent un schéma de requêtes standardisé, débutant par l'indicateur "Q. " suivi d'un résumé de la plainte, puis d'un saut de ligne (\n) introduisant le développement détaillé du patient.
- **Exemple type** : "Q. What should I do to reduce my weight gained due to genetic hypothyroidism?\nHi doctor..."

Cohérence de la colonne output

- **Formules de salutation** : Les réponses médicales débutent généralement par des salutations classiques telles que "Hi.", "Hi there", "Hello.", ou "Hello, Welcome to the icliniq.com."
- **Mentions de masquage d'identité** : L'enregistrement numéro 7 comporte une note

explicite indiquant une modification de sécurité : "(attachment removed to protect patient identity)". Une mention similaire se retrouve à l'enregistrement 11.

4. Audit de Propreté Textuelle (Bruit et Typographie)

Bien que le dataset soit complet sur le plan structurel, l'analyse textuelle révèle du bruit, des coquilles typographiques importantes et des erreurs de saisie manuelle dans les réponses médicales (output).

Erreurs typographiques et orthographiques identifiées

- **Enregistrement 2 (Acné)** : Présence de plusieurs fautes de frappe majeures dans le texte médical :
 - "ypu" au lieu de "you" ("*if ypu have grade 2*").
 - "acud" au lieu de "acid" ("*retenoic acud derivative*").
 - "aluke" au lieu de "like" ("*oral medicines aluke doxycycline*").
- **Enregistrement 7 (Alopécie)** : Une coupure de mot incorrecte : "He ce" au lieu de "Hence" ("*He ce I need detail case history*").
- **Enregistrement 9 (Augmentin)** : Plusieurs anomalies de saisie :
 - "yougurt" et "Kefir." répété deux fois de suite ("*take yougurt, Kefir (fermented yougurt), Kefir. and there are certain*").
 - Manque d'espacement après un point de ponctuation ("*before meals.for 2 weeks.*").
- **Enregistrement 10 (Extraction dentaire)** : Inversion sémantique probable ou faute de frappe : "splitting" utilisé à la place de "spitting" ("*be careful with splitting (do not do it forcefully)*").

Jargon technique ou erreurs de transcription des patients (instruction)

- **Enregistrement 4 (Angoisse HIV)** : Le patient utilise des termes approximatifs ou altérés : "I did not eject" au lieu de "ejaculate".
- **Enregistrement 12 (Retard de règles)** : Orthographe altérée d'un médicament : "post-pill" au lieu de "morning-after pill" ou "emergency contraceptive", et utilisation de "Gestin".

5. Observations et Anomalies d'Intégrité

Note sur la cohérence des diagnostics : Dans l'enregistrement numéro 6 (Beta Strep), la réponse du médecin mentionne de manière incongrue : "*But after a surgery like what you had...*". Or, la question associée (l'instruction) ne mentionne nulle part une quelconque intervention chirurgicale subie par la patiente, mais uniquement un prélèvement gynécologique révélant une infection à levures et un streptocoque bêta. Cela met en évidence un problème potentiel de désalignement sémantique ou de mélange de textes lors de la constitution de la base de données.

6. Conclusion et Recommandations

1. **Nettoyage orthographique nécessaire** : Il est fortement recommandé d'appliquer un

correcteur d'orthographe ou un filtre de normalisation textuelle sur la colonne output pour éliminer les fautes de frappe bloquantes (ypu, acud, aluke, les répétitions de mots) avant toute phase d'apprentissage machine.

2. **Validation des correspondances** : Un contrôle humain ou un réalignement algorithmique est suggéré pour valider la stricte correspondance entre les questions et les réponses, afin d'éviter des cas d'incohérence contextuelle comme celui observé sur l'enregistrement 6.